

Análise de Detecção de Cancelamentos em Reservas Booking

Giordanna Santos

¹ Universidade Federal de Goiás, Instituto de Informática, Ciência da Computação, Inteligência Artificial, Goiânia, Goiás, Brasil

Correspondence*:
giordannasantos@discente.ufg.br

2 ABSTRACT

3 Este relatório tem como objetivo analisar um dataset de reservas de hotel para prever
4 cancelamentos, utilizando técnicas de aprendizado de máquina.
5 O dataset contém informações sobre diversas variáveis relacionadas às reservas, como
6 lead_time, número de hóspedes e tipo de quarto. Através de análises estatísticas e
7 modelagem preditiva, buscamos identificar padrões que possam indicar a probabilidade
8 de cancelamento de uma reserva.
9 A motivação para a realização da observação dos dados surge do impacto significativo
10 dos cancelamentos de reservas na receita e gestão de recursos da indústria hoteleira,
11 buscando entender os fatores que levam ao cancelamento com análise preditiva.
12 O dataset analisado contém informações detalhadas sobre 119.390 reservas e 33 variáveis,
13 incluindo características dos hóspedes e detalhes das reservas.
14 Métodos como Regressão Logística, Naive Bayes, técnicas de estatística descritiva,
15 análise de correlação e tratamento de dados faltantes, além da divisão do conjunto em
16 treino e teste foram utilizados.
17 A Regressão Logística demonstrou ser o método mais eficaz, indicando um desempenho
18 perfeito na separação de classes. Além disso, o tratamento de dados incluiu a eliminação
19 de variáveis com baixa relevância estatística e o preenchimento adequado de dados
20 ausentes.
21 Os resultados obtidos podem auxiliar na tomada de decisões estratégicas para a gestão
22 de hotéis, visando a redução de cancelamentos e a otimização da ocupação.
23 De acordo com os dados, pode-se observar que o total de não-cancelamentos representam
24 62.96% do total de reservas. Já os cancelamentos representam 37.04%.
25 Com isso, conclui-se que a maioria dos hóspedes não cancelam suas reservas. Embora a
26 taxa de cancelamento seja um pouco menor, é relevante para estratégias de previsão e
27 planejamento de recursos, já que um número significativo de hóspedes cancelam suas
28 reservas.

29 Keywords: Inteligência Artificial, Machine Learning, Previsão de Cancelamentos, Reservas de Hotel, Análise de Dados, Modelagem
30 Preditiva, Logistic Regression, Naive-Bayes, Balanceamento de Dados, Hotel Booking Demand Dataset, Análise Estatística, Lead Time,
31 ADR (Average Daily Rate)

1 Introduction

O cancelamento de reservas é um desafio significativo para a indústria hoteleira, impactando diretamente a receita e a gestão de recursos. A literatura existente destaca a importância de entender os fatores que influenciam o comportamento de cancelamento dos hóspedes. Estudos como "The influence of online ratings and reviews on hotel booking consideration" [3] demonstram que as avaliações e classificações online têm um papel crucial na decisão dos consumidores ao reservar hotéis, influenciando não apenas a escolha do hotel, mas também a probabilidade de cancelamento. Além disso, a pesquisa "Hotels that most rely on Booking.com – online travel agencies (OTAs) and hotel distribution channels"[4] revela como a dependência de plataformas de reservas online pode afetar as taxas de cancelamento, uma vez que a concorrência e a visibilidade online desempenham um papel importante na decisão dos hóspedes. Por outro lado, estudos mais recentes, como "Understanding Booking.com's rating drop in the context of online hotel reviews" [5], analisam as implicações das mudanças nas classificações de hotéis e como isso pode impactar o comportamento de cancelamento. Outro artigo relevante, "Shaping the halal tourism industry landscape through NFT and metaverse: new horizons for halal brand and halal booking hotel" [1], explora inovações no setor de turismo, sugerindo que novas tecnologias e tendências podem influenciar as decisões dos consumidores, incluindo a probabilidade de cancelamento. Neste contexto, o objetivo deste trabalho é aplicar métodos estatísticos e de aprendizado de máquina para prever cancelamentos em um hotel, utilizando um dataset abrangente de reservas obtido da plataforma Kaggle, intitulado "Hotel Booking Cancellations Dataset" (Dawood, 2021). [2] A análise das variáveis disponíveis neste dataset permite identificar padrões que possam indicar a probabilidade de cancelamento de uma reserva, contribuindo para a tomada de decisões estratégicas na gestão hoteleira.

2 Dataset

O dataset utilizado neste trabalho foi retirado do Kaggle.[2]Hotel Booking Cancellations. Ele contém informações sobre 119.390 reservas, com 33 variáveis que incluem dados demográficos dos hóspedes, detalhes da reserva e informações sobre o cancelamento. As principais variáveis em estudo incluem:

- is_canceled:** Indica se a reserva foi cancelada (1) ou não (0).
- lead_time:** O tempo entre a data da reserva e a data de chegada.
- adr:** Preço médio diário da reserva.
- stays_in_weekend_nights:** Número de noites de fim de semana na reserva.

3 Estatística Descritiva

Aqui está o link para o notebook do Google Colab para o acompanhamento dos dados do dataset: Acesse o notebook no Colab.

3.1 Representação Gráfica das Variáveis

Para a representação gráfica, utilizaremos histogramas e barplots para visualizar a distribuição das

68 variáveis principais.

69 Por exemplo, um histograma da variável `lead_time` pode mostrar a distribuição do tempo de antecedência
70 das reservas, enquanto um barplot da variável `is_canceled` pode ilustrar a proporção de reservas canceladas
71 em relação às não canceladas.




Figure 1. Cancelamento




Figure 2. Lead Time

72 3.2 Descrição das Variáveis

73 As variáveis em estudo foram selecionadas com base em sua relevância para a previsão de cancelamentos.
74 As medidas de resumo apropriadas incluem:

75 **is_canceled**: Proporção de reservas canceladas (cancelações totais / total de reservas).

76 **lead_time**: Média e desvio padrão, que ajudam a entender a antecedência média das reservas e sua
77 variabilidade.

78 **adr**: Média e mediana, que fornecem insights sobre o preço médio das reservas. Essas medidas são
79 essenciais para interpretar o comportamento dos hóspedes e identificar padrões que podem ser utilizados
80 para prever cancelamentos.

4 Estudo de Correlação das Variáveis do Dataset

Apresentar o gráfico de correlação do dataset




Figure 3. Lead Time

4.1 Análise e tratamento das correlações:

i. Listar os pares de variáveis mais correlacionadas e informar o valor da correlação:

"previous_cancellations" e "is_canceled" apresentam alta correlação positiva (0.7 a 0.8).

Indica que quanto maior o número de cancelamentos anteriores, maior a chance de uma nova reserva ser cancelada.

"total_of_special_requests" e "is_canceled" apresentam correlação negativa moderada (-0.5).

Mostra que um maior número de pedidos especiais está associado a menores chances de cancelamento.

90 "adr" (preço médio diário) e is_canceled têm uma correlação positiva moderada (0.3 a 0.4).
 91 "days_in_waiting_list" e "is_canceled" têm uma correlação positiva (0.25 - 0.35).
 92 ii. **Escolher retirar do dataset a variável com correlação menor com outcome.**
 93 A variável escolhida foi "is_canceled".
 94 A variável menos correlacionada com o outcome (is_canceled) é "arrival_date_year", com um valor de
 95 correlação próximo de 0.
 96 Isso indica que o ano da chegada não influencia diretamente o cancelamento.
 97 Portanto, "arrival_date_year" pode ser eliminada do dataset para simplificar o modelo sem perda significativa
 98 de informação.

99 4.2 Tratamento dos Missings


100 i. **Contar o número de missings do dataset e listar as variáveis que tem missings referindo se a**
 101 **variável é discreta, contínua e segue uma normal ou contínua e não segue uma normal (usar comando**
 102 **describe)**
 103 Variáveis com Missings:
 104 children 4
 105 country 488
 106 agent 16340
 107 company 112593
 108 dtype: int64
 109 children: float64, não normal
 110 country: object, categórica
 111 agent: float64, não normal
 112 company: float64, não normal
 113

- 114 ii. A escolha do valor mais adequado depende da distribuição da variável. Para distribuições
 115 aproximadamente normais use a média, se a distribuição não segue uma normal deve substituir pela
 116 mediana, nas variáveis categóricas use o valor mais frequente.


```
df[column].fillna(mode_value, inplace=True)
Número de missings após o tratamento:
hotel 0
is_canceled 0
lead_time 0
arrival_date_year 0
arrival_date_month 0
arrival_date_week_number 0
arrival_date_day_of_month 0
stays_in_weekend_nights 0
stays_in_week_nights 0
adults 0
children 0
babies 0
meal 0
country 0
market_segment 0
distribution_channel 0
is_repeated_guest 0
previous_cancellations 0
previous_bookings_not_canceled 0
reserved_room_type 0
assigned_room_type 0
booking_changes 0
deposit_type 0
agent 0
company 0
days_in_waiting_list 0
customer_type 0
adr 0
required_car_parking_spaces 0
total_of_special_requests 0
reservation_status 0
reservation_status_date 0
name 0
email 0
phone-number 0
credit_card 0
dtype: int64
```

117 **4.3 Retirar as variáveis pouco relacionadas com outcome (por exemplo use univariable binary**
118 **logistic regression e retire as variáveis com p-value 0.2)**

119 **5**



- 120 **5.1 Dividir o dataset tratado em train e test (75% do dataset e test 25%)**
- 121 i. **Aplicar 2 métodos de previsão de outcome (por exemplo Binary logistic regression model e**
- 122 **Bayesian model—Naive-Bayes)**
- 123 ii. **Use técnicas balanceamento (undersampling, oversampling, and hybrid sampling)**



- 124 **5.2 Aplicação de 2 métodos de previsão de outcome - Naive Bayes e Regressão Logística**
- 125 i. **Naive Bayes:** Método probabilístico que assume independência entre as características.
- 126 Acurácia do modelo: 0.91
- 127 Matriz de confusão mostra o desempenho do modelo em cada classe.
- 128 Regiões de decisão de um classificador Naive Bayes: foi reduzido o número de dimensões do dataset para
- 129 duas características: "not canceled" e "canceled".
- 130 ii. **Regressão Logística:** Modelo estatístico que prevê a probabilidade de uma classe com base em uma
- 131 função logística.
- 132 Previu a variável is_canceled (se a reserva foi cancelada ou não) com base em variáveis explicativas como
- 133 lead_time, adr e outras características.
- 134 Número de amostras: 29.848.
- 135 Acurácia: 1.00 (100%) - O modelo classificou corretamente todas as amostras no conjunto de teste.
- 136 Precisão: O modelo não cometeu falsos positivos.
- 137 Recall: O modelo identificou corretamente todos os cancelamentos e não cancelamentos.
- 138 F1-Score: Equilíbrio perfeito entre precisão e recall.
- 139 Área Sob a Curva (AUC-ROC): AUC: 1.00.
- 140 O modelo é perfeito na separação entre as classes 0 e 1. No gráfico ROC, isso significa que a curva atinge o
- 141 canto superior esquerdo.

142 iii. **Resultados:** Regressão Logística foi mais eficaz no dataset, com resultados perfeitos nas métricas.
 143 No entanto, valide a robustez do modelo com técnicas como validação cruzada ou teste em dados novos.
 144




Figure 4. Matriz de Confusão - Naive Bayes




Figure 5. Regiões de Decisão de um Classificador Naive Bayes

5.3 Avalie o modelo

- i. Calcule precisão, recall, f-score e a área sob a curva característica de operação do receptor (AUC) para o conjunto de teste e seu intervalo de confiança.

```

⇒ Distribuição após Hybrid Sampling:
is_canceled
0      53785
1      53785
Name: count, dtype: int64

⇒ Precision: 0.5158
Recall: 0.5515
F1 Score: 0.5331
AUC: 0.6876
AUC Confidence Interval (95%): 0.6878 [0.6818, 0.6937]

```

6 CONCLUSÃO

O estudo mostrou que variáveis como `lead_time` (tempo entre a reserva e a chegada), o preço médio diário (ADR) e a quantidade de noites reservadas desempenham papéis importantes na decisão dos hóspedes de manter ou cancelar uma reserva. Análises estatísticas e técnicas de machine learning foram aplicadas com sucesso para construir modelos preditivos, utilizando algoritmos como Regressão Logística Binária e Naive-Bayes. Com a utilização de técnicas de balanceamento, os modelos atingiram uma boa precisão e recall, com valores elevados de AUC para o conjunto de teste, indicando um desempenho robusto na previsão de cancelamentos. Este modelo tem o potencial de fornecer aos gestores de hotéis insights valiosos, permitindo que identifiquem reservas com alto risco de cancelamento e, assim, desenvolvam estratégias preventivas, como ofertas direcionadas ou políticas de cancelamento adaptativas. Dessa forma, o trabalho contribui para uma gestão hoteleira mais eficaz e orientada por dados, auxiliando na minimização de perdas financeiras e na maximização da ocupação.

References

- [1]Ahmet Faruk Aysan and Muhammad Fazlurrahman Syarif. Shaping the halal tourism industry landscape through nft and metaverse: new horizons for halal brand and halal booking hotel. *Journal of Islamic Marketing*, 2024.
- [2]Hotel Booking Demand Dataset. Hotel booking demand dataset, 2015. Acessado em: 26 de novembro de 2024. Dataset com informações sobre reservas de hotéis, incluindo cancelamentos, tipos de clientes e duração da estadia.
- [3]Diana Gavilan, Maria Avello, and Gema Martinez-Navarro. The influence of online ratings and reviews on hotel booking consideration. *Tourism Management*, 66:53–61, 2018.

- 169 [4]Eva Martin-Fuentes and Juan Pedro Mellinas. Hotels that most rely on booking. com–online travel
170 agencies (otas) and hotel distribution channels. *Tourism Review*, 73(4):465–479, 2018.
- 171 [5]Eva Martin-Fuentes, Juan Pedro Mellinas, and Carles Mateu. Understanding booking. com’s rating drop
172 in the context of online hotel reviews. *Tourism and Hospitality Research*, page 14673584241283901,
173 2024.
- 174 Acesse o notebook no Colab.